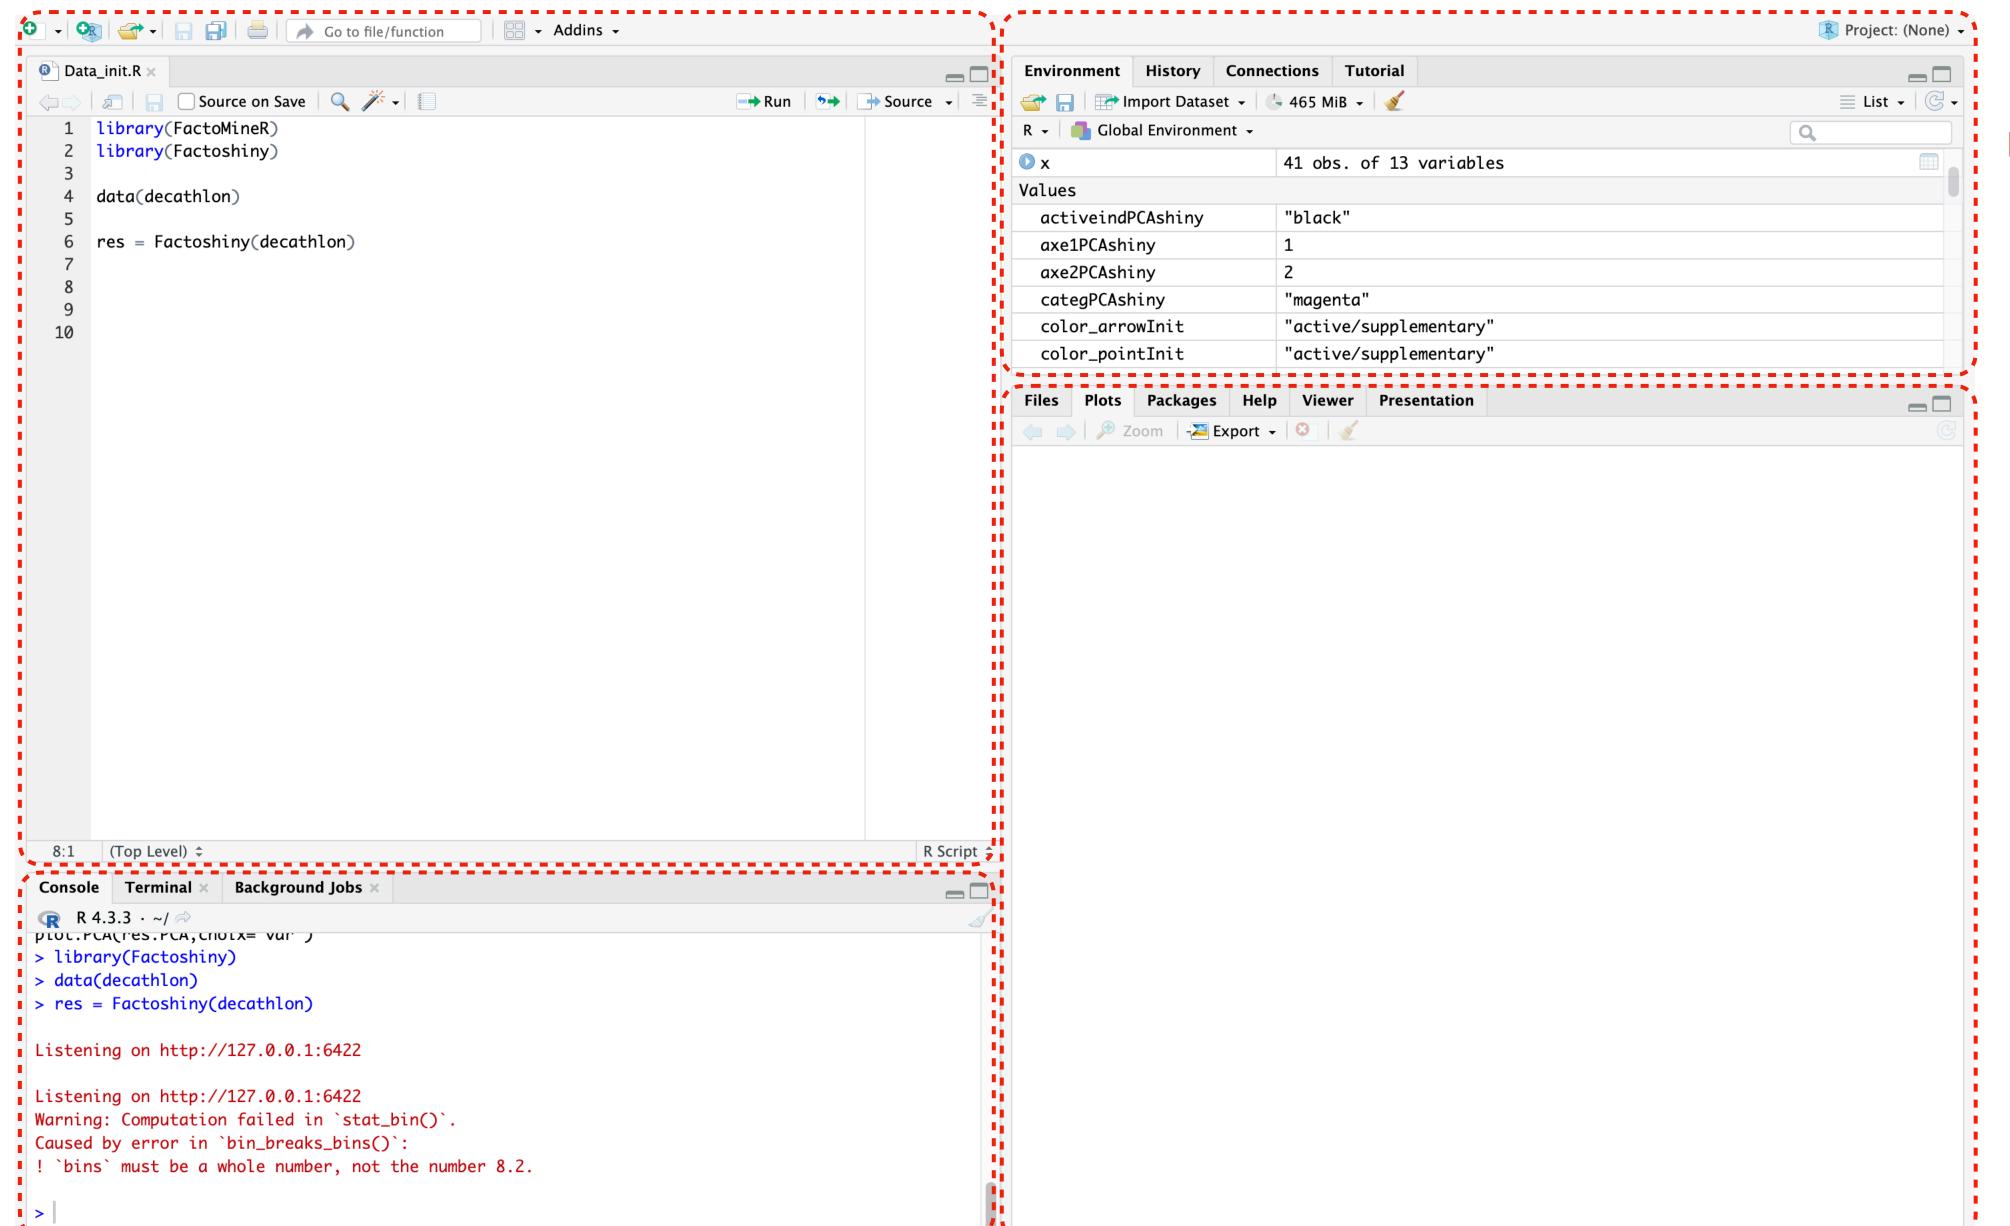


## Data analysis and Exploration using R

Dimensionality reduction

### Introduction to R



Environment Variables History

> Plots Help Files

#### R console Terminal

**Code Editor** 

#### R: Introduction

- Install and load library
  - > install.packages("ggplot2") # Install new library
  - > library(ggplot2) # Load library
- Visualise documentation for a function or library
  - > ?mean # or help(mean)
  - > help("PCA", package = "FactoMineR")
  - > example(mean)
- Load preloaded datasets
  - > data(cars)
  - > library(help = "datasets")
  - > view(cars)

#### R: Data Frames

A data frame is a table of data in R:

- each row = one individual (or observation),
- each column = one variable (or attribute),
- o columns can be of different types (numeric, text, factor, etc.).
- > class(cars)
- > is.data.frame(cars)

```
> df = data.frame(
    Nom = c("Alice", "Bob", "Clara"),
    Age = c(23, 25, 22),
    Sexe = c("F", "M", "F")
)
```

#### R: Manipulate Data Frames

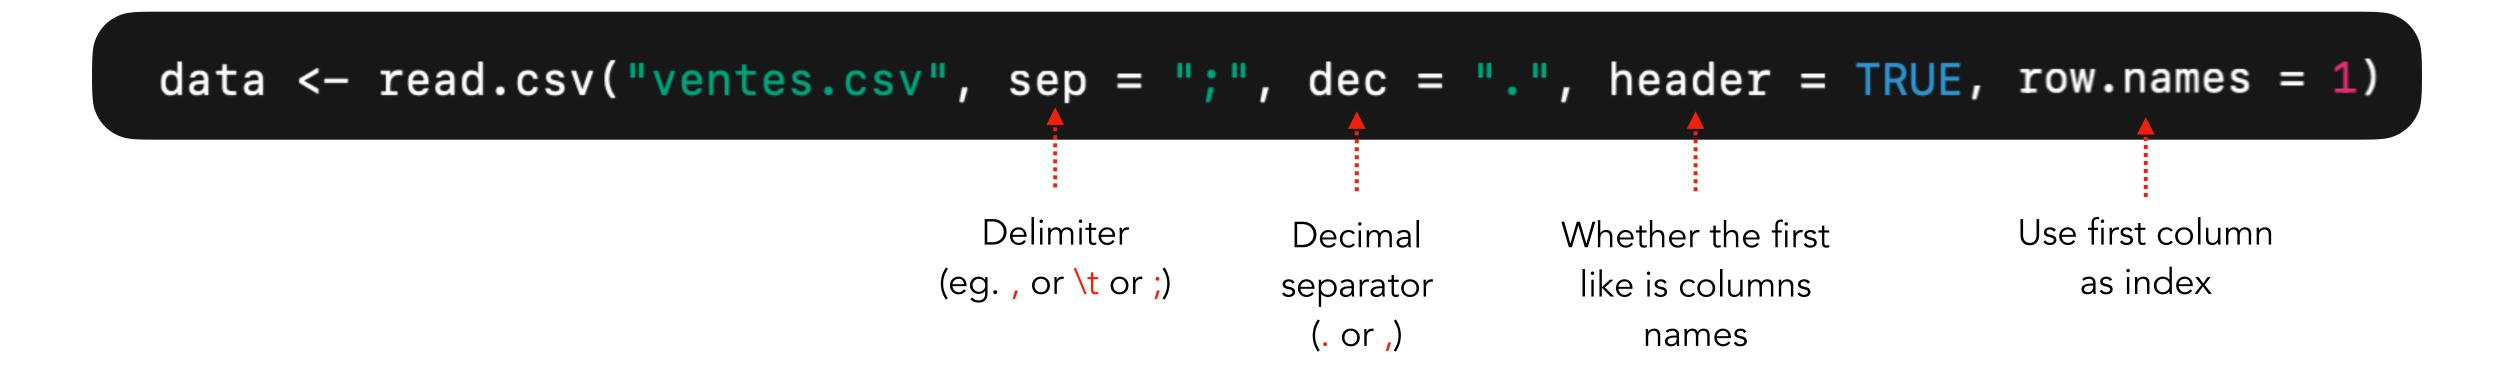
> head(cars)
> summary(cars)
> head(mtcars)
> names(mtcars) # Show column names
> mtcars\$hp <- NULL # Delete a column
> mtcars <- mtcars[-2,] # Delete a row
> mtcars\$new\_var <- I:nrow(mtcars) # Add a column</pre>

#### R: Read csv

Example of csv file

```
Name; City; Sallary; Year
Alpha; Paris; 22000; 2023
Beta; Lyon; 69500; 2023
Gamma; Marseille; 33400; 2023
Delta; Paris; 12000; 2024
```

• Read csv file



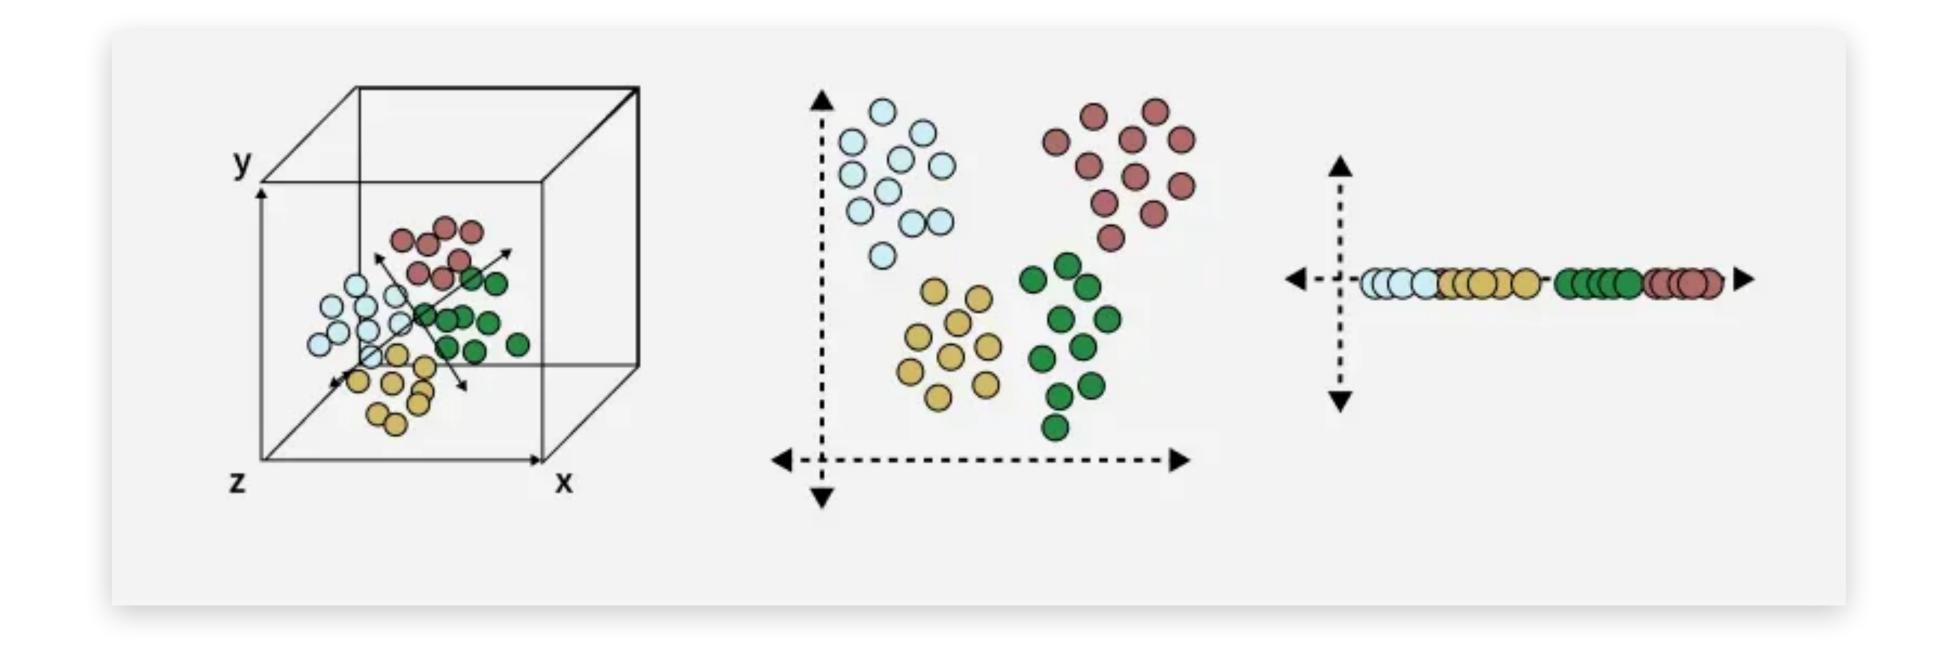
#### A envoyer à : mlds.git@gmail.com

- 1. Charger un dataset intégré
  - 1. Chargez le jeu de données **mtcars**.
  - 2. Visualiser les données sous forme de table.
  - 3. Affichez les 5 premières lignes et le résumé des variables.
- 2. Modifier le dataset
  - 1. Supprimez la colonne drat.
  - 2. Ajoutez une colonne prix avec des valeurs aléatoires entre 10000 et 40000.
  - 3. Supprimez la première ligne du tableau.
- 3. Ajouter une nouvelle ligne
  - 1. Créez une ligne avec vos propres valeurs et ajoutez-la à la fin.
- 4. Sauvegarder et réimporter
  - 1. Sauvegardez votre table CSV en utilisant write.csv (utiliser ?write.csv pour afficher l'aide.)
  - 2. Réimportez-la avec read.csv() et vérifiez les données.

## Dimensionality Reduction

#### What is dimensionality reduction

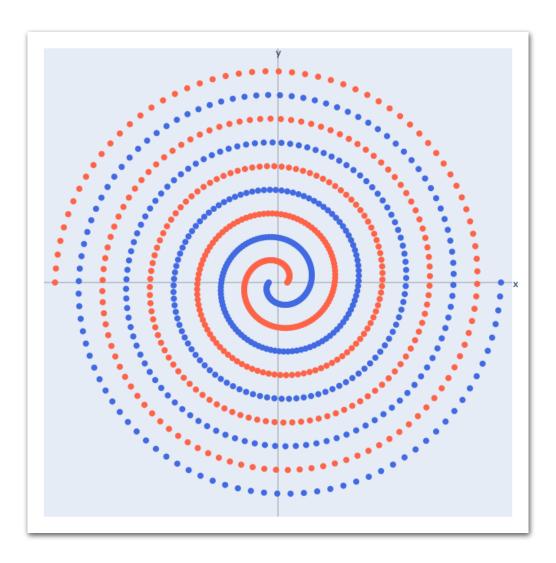
- Dimensionality reduction projects high-dimensional data into a lower-dimensional space while keeping as much useful information as possible.
- It can be used to:
  - Simplify visualization (e.g., 2D/3D plots of complex datasets).
  - Reduce noise and improve machine learning performance.



#### **PCA: Principal Component Analysis**

Principal Component Analysis (PCA) is a linear and fast method based on linear algebra.

- Finds axes (principal components) that maximize the variance of the data.
- Each component is a linear combination of the original variables.
- Useful for reducing dimensionality while keeping most of the variance.
- Limitation: cannot capture non-linear structures in the data (relation between data is non linear)



# Dimensionality Reduction using Factorial

#### PCA using FactoMineR

- FactoMineR is an R package (developed by the team of François Husson) dedicated to multivariate exploratory data analysis. The main goal is to simplify complex multivariate analyses and make them accessible and interpretable.
- It provides functions for the most common multivariate methods, such as:
  - Principal Component Analysis (PCA)
  - Correspondence Analysis (CA)
  - Multiple Correspondence Analysis (MCA)
  - Hierarchical Clustering (HCPC)
  - and several extensions (MFA, MFAmix, etc.).
- FactoMineR automatically produces:
  - ◆ Tables of eigenvalues, contributions, and squared cosines (cos²)
  - Graphical outputs (individuals, variables, biplots)
  - Interpretation aids (which variables/individuals influence each axis)

#### PCA using FactoMineR

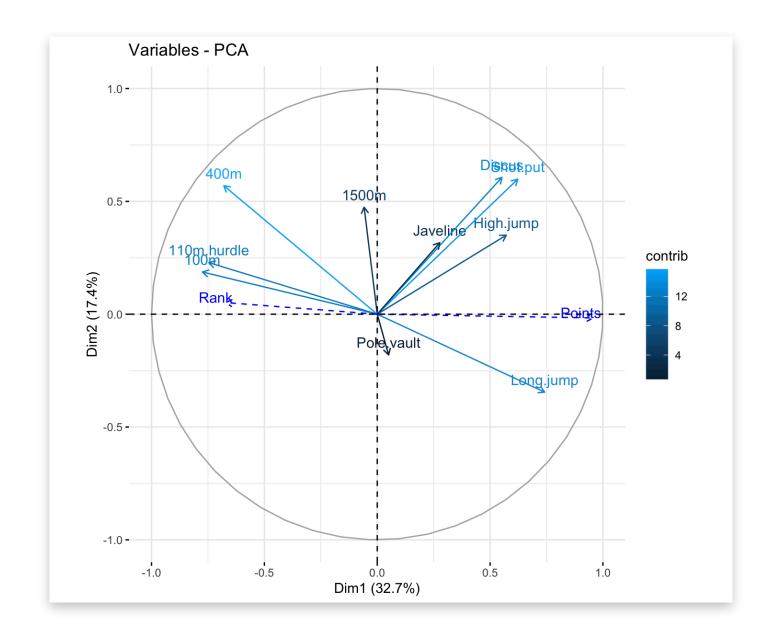
Load Library

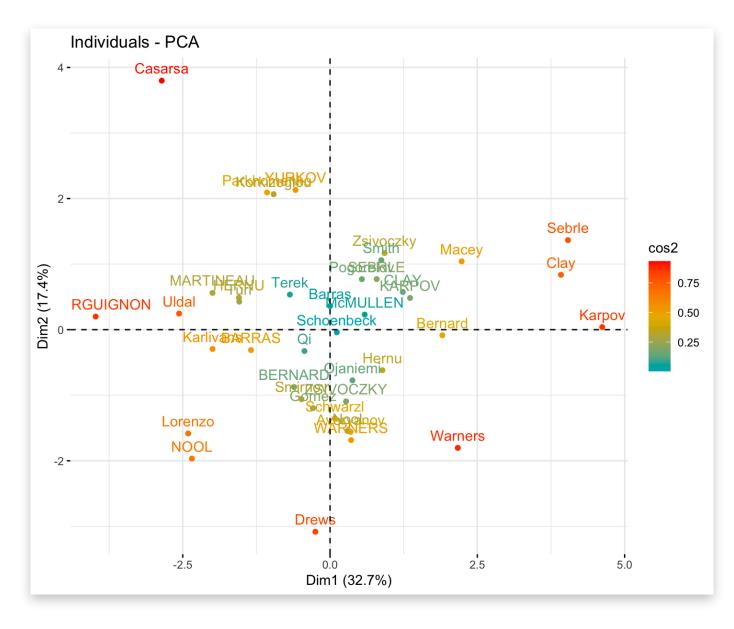
- > install.packages(c("FactoMineR", "factoextra"))
- > library(FactoMineR)
- > library(factoextra)
- Run PCA on USArrests dataset
  - > res.pca <- PCA(USArrests)
- Basic plots
  - > plot(res.pca, choix = "var") # Plot of variables
  - > plot(res.pca, choix = "ind") # Plot of individuals

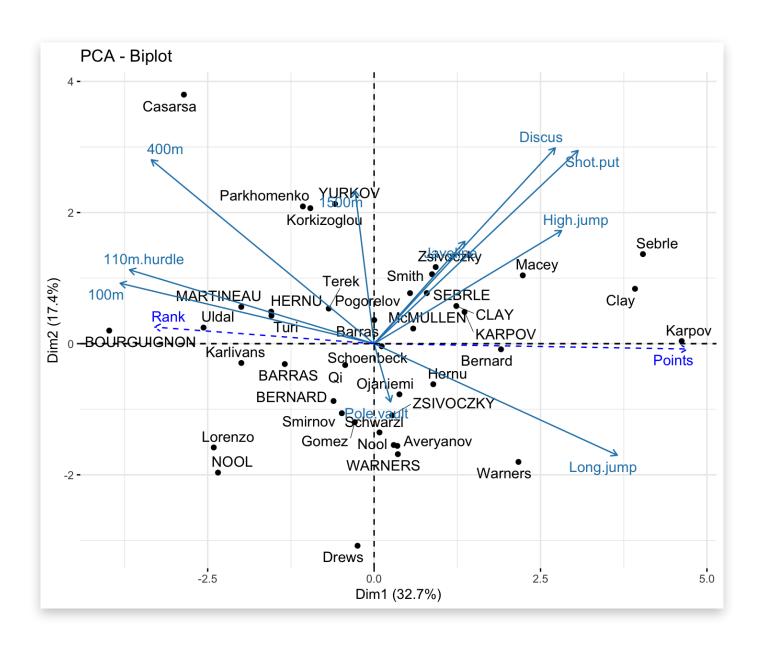
#### PCA using FactoMineR and factoextra

Use factoextra for better visualization

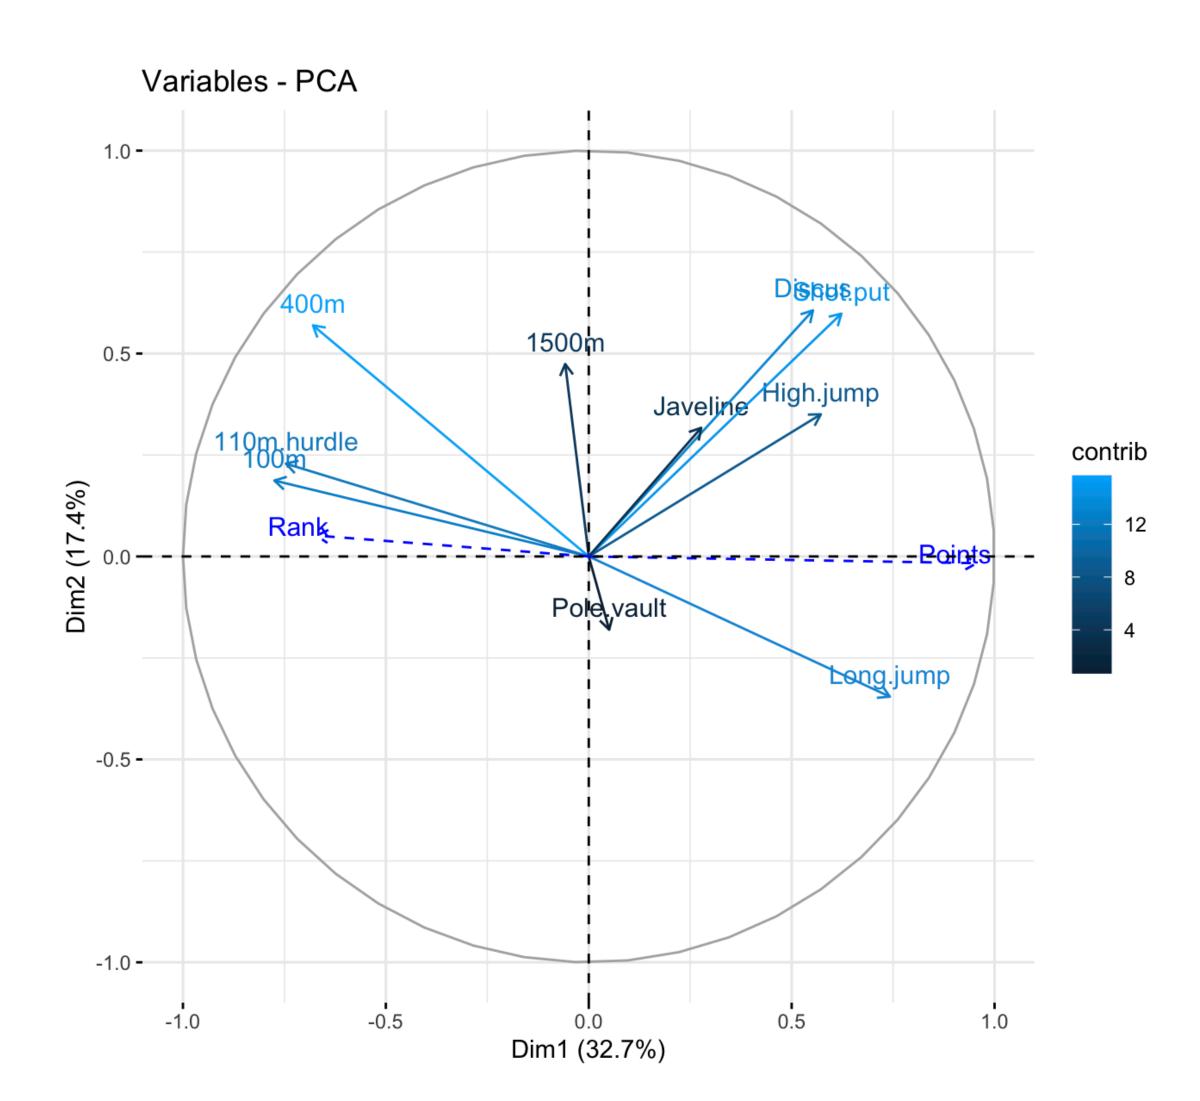
```
fviz_eig(res.pca, addlabels = TRUE, ylim = c(0, 50)) # Scree plot
fviz_pca_var(res.pca, col.var = "contrib") # Variables
fviz_pca_ind(res.pca, col.ind = "cos2", gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"))
fviz_pca_biplot(res.pca, repel = TRUE) # Biplot
```







#### PCA using FactoMine: Variables plot interpretation



- Each arrow represents a quantitative variable.
- The direction and length of an arrow show how much that variable contributes to the axes. Longer arrows → better represented on the plane (higher cos²).
- ▶ The angle between arrows indicates correlation between variables:
  - Small angle (close arrows) → strong positive correlation.
  - Opposite directions (180°)  $\rightarrow$  strong negative correlation.
  - $\circ$  Perpendicular (90°)  $\rightarrow$  very weak correlation.
- Variables close to the same axis are the ones that define that component the most.

**Objectif.** Réaliser une ACP sur les données decathlon. Les données portent sur des athlètes ayant participé à un décathlon (10 épreuves d'athlétisme). Chaque ligne correspond à un athlète, chaque colonne à une épreuve : 100m, longueur, poids, hauteur, 400m, 110m haies, disque, perche, javelot et 1500m. L'objectif est de comprendre comment ces épreuves sont reliées entre elles, quelles dimensions principales structurent la performance globale.

#### 1. Préparation et exploration

- o Sélectionner les variables quantitatives correspondant aux dix épreuves.
- Examiner la structure et le résumé statistique du jeu de données.
- o Expliquer brièvement le type de variables et les unités mesurées.

#### 2. Réaliser une ACP

- Effectuer une ACP sur les dix épreuves uniquement et considérer le reste en variables supplémentaires.
- o Afficher le cercle des corrélations des variables avec FactoMineR avec factoextra.
- Identifier les variables fortement corrélées, ceux qui sont bien représentées, et ceux qui contribuent le plus aux deux premiers axes.
- o Interpréter les deux premiers axes : que semble représenter le premier axe ? Que semble représenter le deuxième axe ?
- o Repérer les grands groupes de variables et les types de performances qu'ils décrivent.