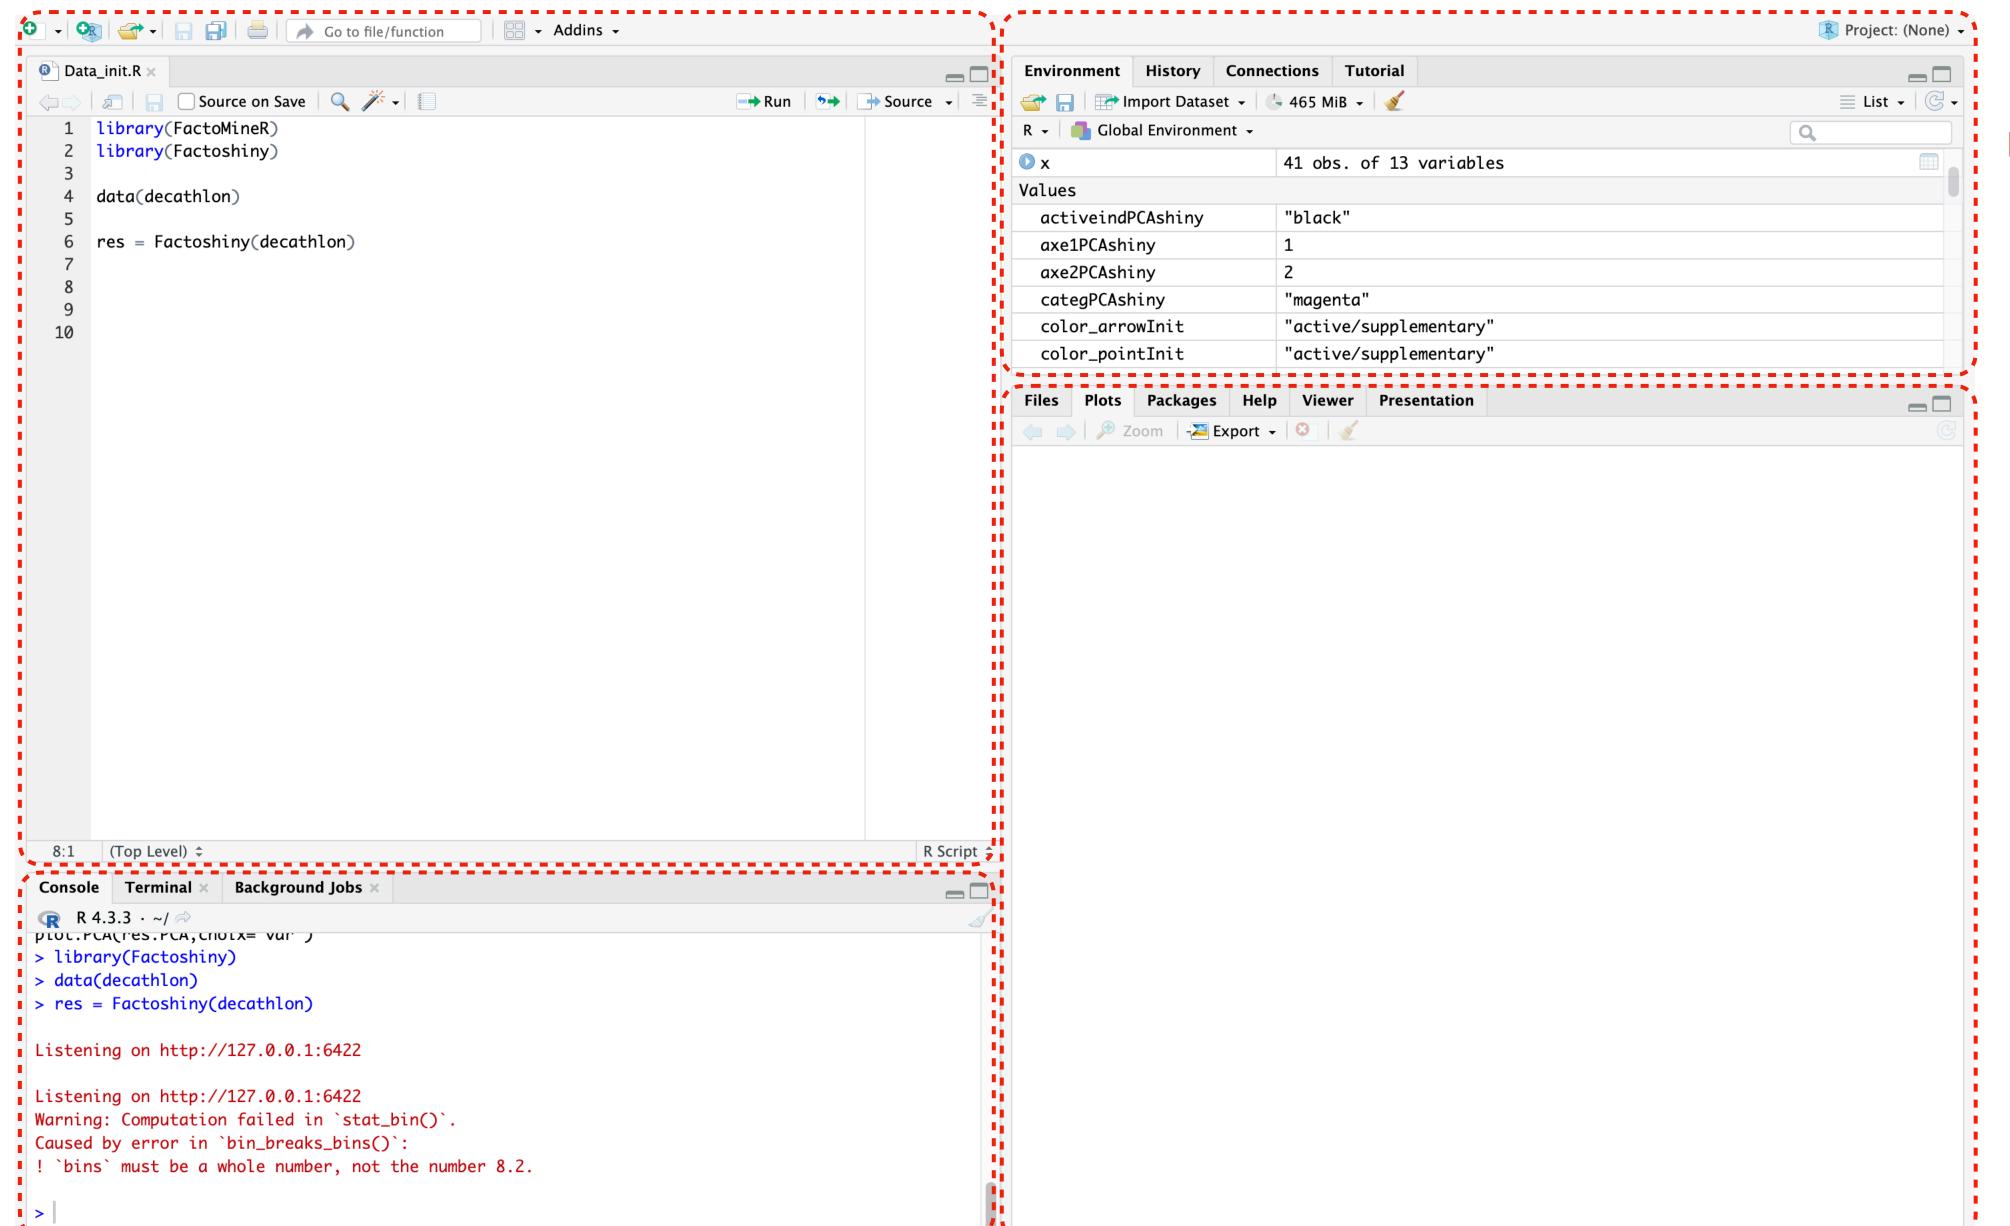


Data analysis and Exploration using R

Dimensionality reduction

Introduction to R



Environment Variables History

> Plots Help Files

R console Terminal

Code Editor

R: Introduction

- Install and load library
 - > install.packages("ggplot2") # Install new library
 - > library(ggplot2) # Load library
- Visualise documentation for a function or library
 - > ?mean # or help(mean)
 - > help("PCA", package = "FactoMineR")
 - > example(mean)
- Load preloaded datasets
 - > data(cars)
 - > library(help = "datasets")
 - > view(cars)

R: Data Frames

A data frame is a table of data in R:

- each row = one individual (or observation),
- each column = one variable (or attribute),
- o columns can be of different types (numeric, text, factor, etc.).
- > class(cars)
- > is.data.frame(cars)

```
> df = data.frame(
    Nom = c("Alice", "Bob", "Clara"),
    Age = c(23, 25, 22),
    Sexe = c("F", "M", "F")
)
```

R: Manipulate Data Frames

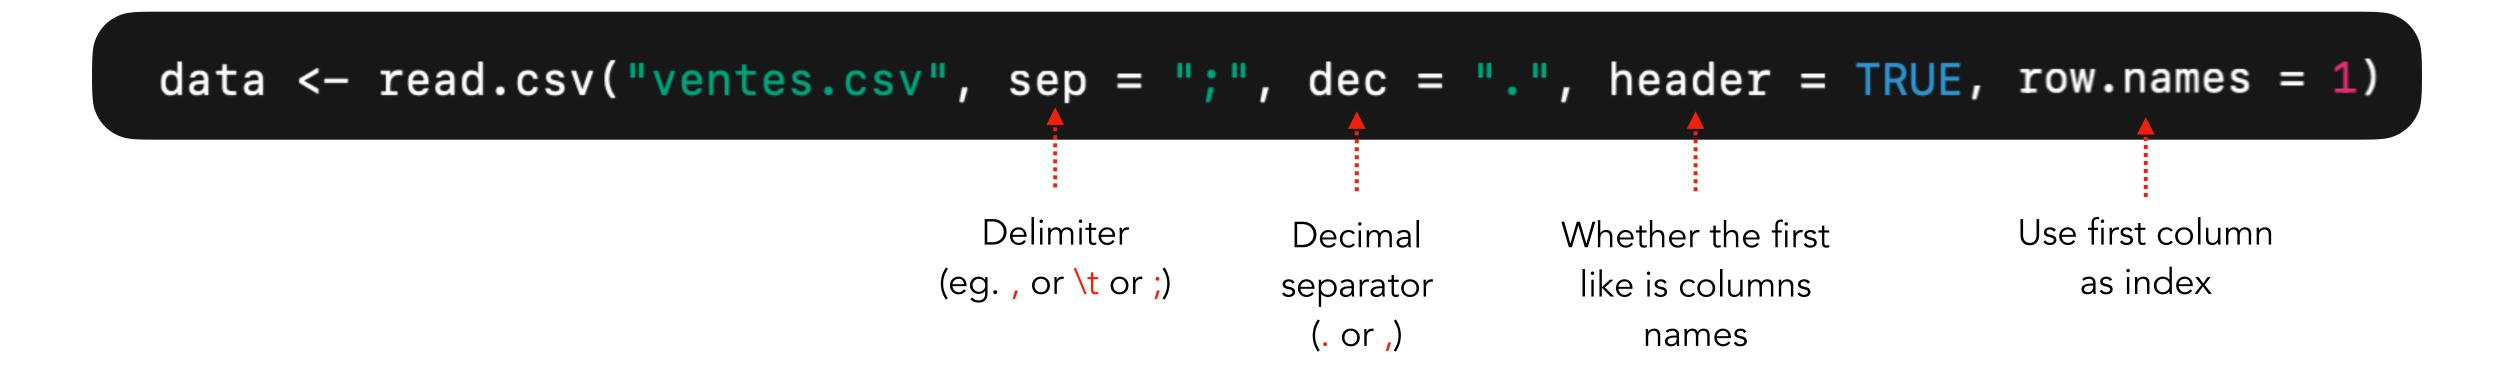
> head(cars)
> summary(cars)
> head(mtcars)
> names(mtcars) # Show column names
> mtcars\$hp <- NULL # Delete a column
> mtcars <- mtcars[-2,] # Delete a row
> mtcars\$new_var <- I:nrow(mtcars) # Add a column</pre>

R: Read csv

Example of csv file

```
Name; City; Sallary; Year
Alpha; Paris; 22000; 2023
Beta; Lyon; 69500; 2023
Gamma; Marseille; 33400; 2023
Delta; Paris; 12000; 2024
```

• Read csv file



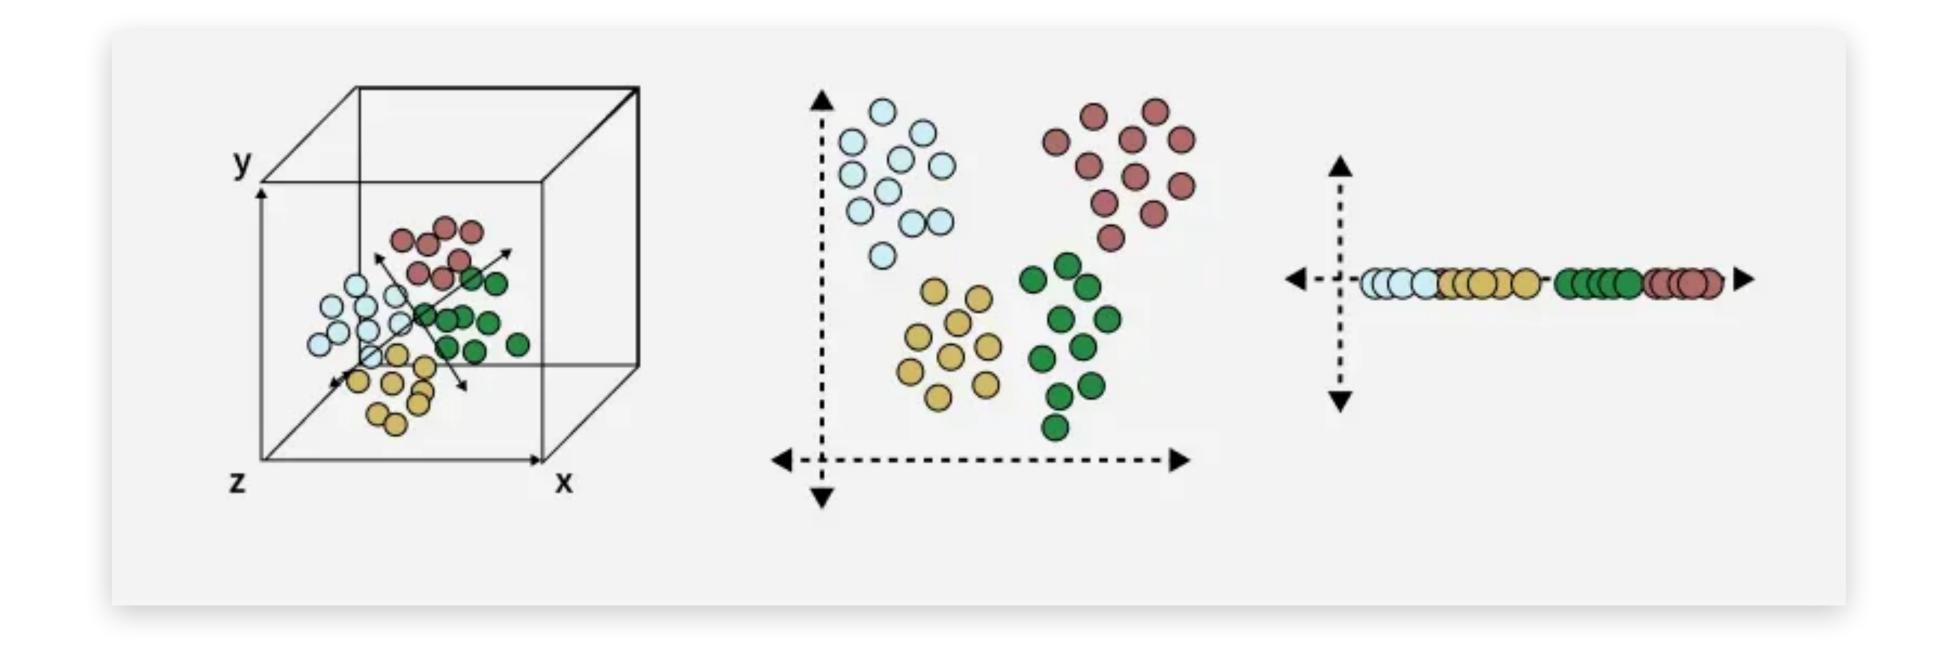
A envoyer à : mlds.git@gmail.com

- 1. Charger un dataset intégré
 - 1. Chargez le jeu de données **mtcars**.
 - 2. Visualiser les données sous forme de table.
 - 3. Affichez les 5 premières lignes et le résumé des variables.
- 2. Modifier le dataset
 - 1. Supprimez la colonne drat.
 - 2. Ajoutez une colonne prix avec des valeurs aléatoires entre 10000 et 40000.
 - 3. Supprimez la première ligne du tableau.
- 3. Ajouter une nouvelle ligne
 - 1. Créez une ligne avec vos propres valeurs et ajoutez-la à la fin.
- 4. Sauvegarder et réimporter
 - 1. Sauvegardez votre table CSV en utilisant write.csv (utiliser ?write.csv pour afficher l'aide.)
 - 2. Réimportez-la avec read.csv() et vérifiez les données.

Dimensionality Reduction

What is dimensionality reduction

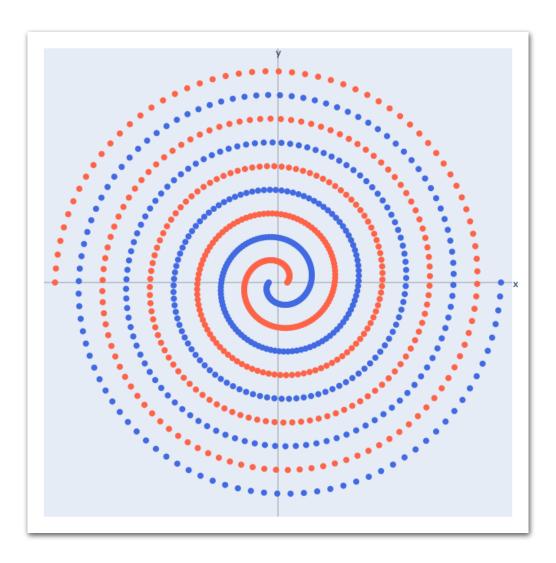
- Dimensionality reduction projects high-dimensional data into a lower-dimensional space while keeping as much useful information as possible.
- It can be used to:
 - Simplify visualization (e.g., 2D/3D plots of complex datasets).
 - Reduce noise and improve machine learning performance.



PCA: Principal Component Analysis

Principal Component Analysis (PCA) is a linear and fast method based on linear algebra.

- Finds axes (principal components) that maximize the variance of the data.
- Each component is a linear combination of the original variables.
- Useful for reducing dimensionality while keeping most of the variance.
- Limitation: cannot capture non-linear structures in the data (relation between data is non linear)



Dimensionality Reduction using Factorial

PCA using FactoMineR

- FactoMineR is an R package (developed by the team of François Husson) dedicated to multivariate exploratory data analysis. The main goal is to simplify complex multivariate analyses and make them accessible and interpretable.
- It provides functions for the most common multivariate methods, such as:
 - Principal Component Analysis (PCA)
 - Correspondence Analysis (CA)
 - Multiple Correspondence Analysis (MCA)
 - Hierarchical Clustering (HCPC)
 - and several extensions (MFA, MFAmix, etc.).
- FactoMineR automatically produces:
 - ◆ Tables of eigenvalues, contributions, and squared cosines (cos²)
 - Graphical outputs (individuals, variables, biplots)
 - Interpretation aids (which variables/individuals influence each axis)

PCA using FactoMineR

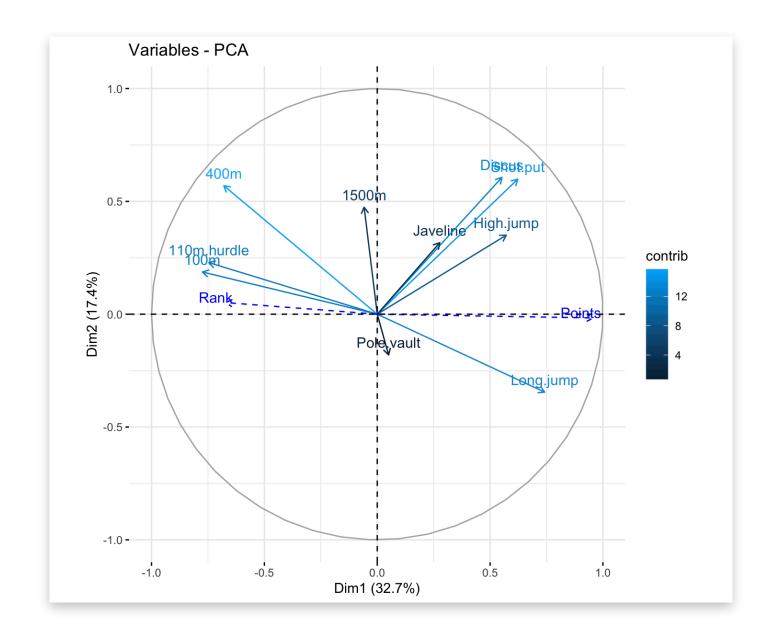
Load Library

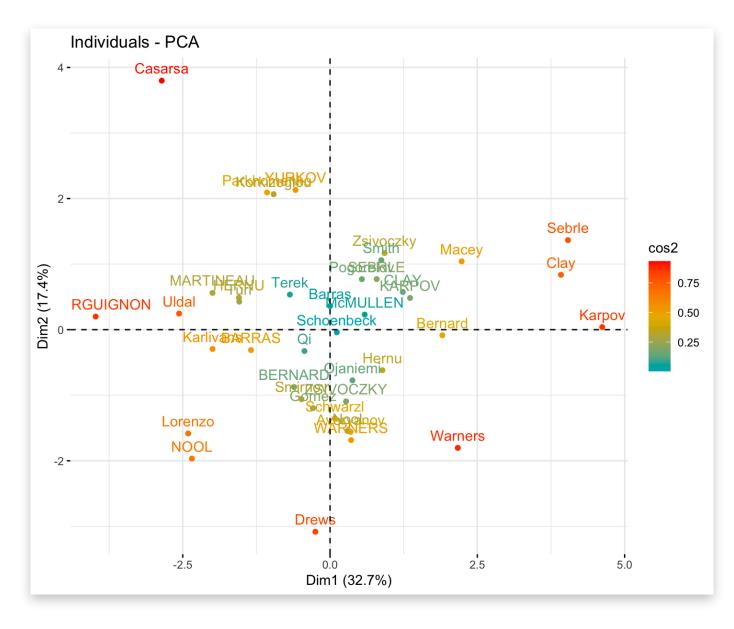
- > install.packages(c("FactoMineR", "factoextra"))
- > library(FactoMineR)
- > library(factoextra)
- Run PCA on USArrests dataset
 - > res.pca <- PCA(USArrests)
- Basic plots
 - > plot(res.pca, choix = "var") # Plot of variables
 - > plot(res.pca, choix = "ind") # Plot of individuals

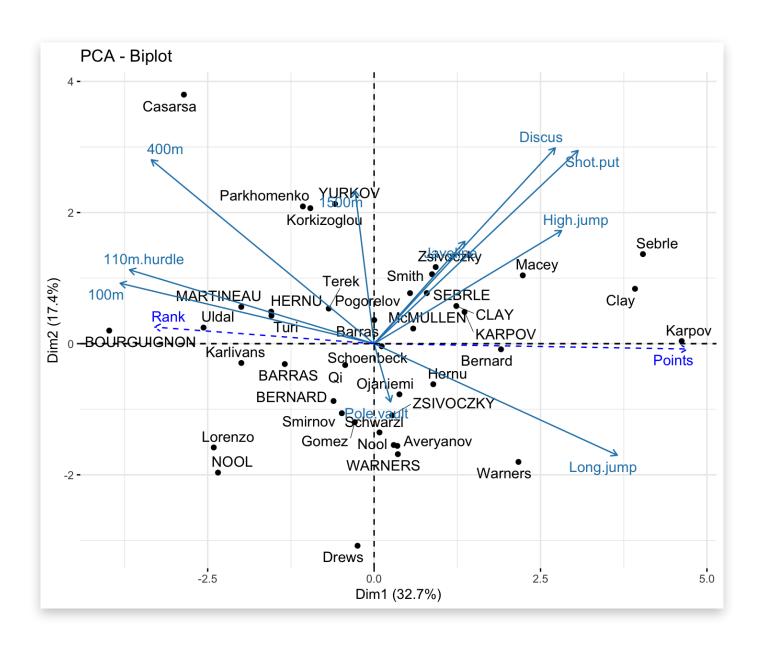
PCA using FactoMineR and factoextra

Use factoextra for better visualization


```
fviz_eig(res.pca, addlabels = TRUE, ylim = c(0, 50)) # Scree plot
fviz_pca_var(res.pca, col.var = "contrib") # Variables
fviz_pca_ind(res.pca, col.ind = "cos2", gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"))
fviz_pca_biplot(res.pca, repel = TRUE) # Biplot
```







PCA using FactoMine: Variables plot interpretation



- Each arrow represents a quantitative variable.
- The direction and length of an arrow show how much that variable contributes to the axes. Longer arrows → better represented on the plane (higher cos²).
- ▶ The angle between arrows indicates correlation between variables:
 - Small angle (close arrows) → strong positive correlation.
 - Opposite directions (180°) \rightarrow strong negative correlation.
 - \circ Perpendicular (90°) \rightarrow very weak correlation.
- Variables close to the same axis are the ones that define that component the most.

Objectif. Réaliser une ACP sur les données decathlon. Les données portent sur des athlètes ayant participé à un décathlon (10 épreuves d'athlétisme). Chaque ligne correspond à un athlète, chaque colonne à une épreuve : 100m, longueur, poids, hauteur, 400m, 110m haies, disque, perche, javelot et 1500m. L'objectif est de comprendre comment ces épreuves sont reliées entre elles, quelles dimensions principales structurent la performance globale.


1. Préparation et exploration

- Sélectionner les variables quantitatives correspondant aux dix épreuves.
- Examiner la structure et le résumé statistique du jeu de données.
- o Expliquer brièvement le type de variables et les unités mesurées.

2. Réaliser une ACP

- Effectuer une ACP sur les dix épreuves uniquement et considérer le reste en variables supplémentaires.
- o Afficher le cercle des corrélations des variables avec FactoMineR avec factoextra.
- Identifier les variables fortement corrélées, ceux qui sont bien représentées, et ceux qui contribuent le plus aux deux premiers axes.
- o Interpréter les deux premiers axes : que semble représenter le premier axe ? Que semble représenter le deuxième axe ?
- o Repérer les grands groupes de variables et les types de performances qu'ils décrivent.

PCA using FactoMine: Variables plot



- Each point represents an individual (here: an athlete).
- The **position** of each individual is determined by their scores (coordinates) on the principal components (Dim1, Dim2, etc.).
- Individuals that are close to each other on the plot have similar performance profiles across all variables.
- ► The axes (Dim1, Dim2) represent **underlying dimensions** (combinations of variables that summarize performance).
- ▶ The color scale (cos²) shows the quality of representation:
 - High $\cos^2 \rightarrow$ the individual is well represented on this plane.
 - Low cos² → less well represented; the individual's pattern may appear on another dimension.
- Individuals far from the origin are more extreme or distinctive (very high or very low scores).

Après avoir étudié les **relations entre variables**, on cherche maintenant à comprendre **comment les athlètes se répartissent** dans l'espace défini par les deux premières dimensions de l'ACP.

- 1. Générer le plot des individus (plan 1-2).
- 2. Observer la répartition générale des athlètes :
 - Le nuage est-il homogène ou structuré ?
 - o Observe-t-on des groupes distincts ou des valeurs extrêmes ?
- 3. Identifier les individus les plus éloignés du centre
 - Que signifie leur position dans le plan ?
 - Quelle information donne la distance à l'origine ?
- 4. Repérer les groupes d'athlètes proches les uns des autres :
 - o Que peut-on en déduire sur leurs profils de performance ?
 - Quels athlètes semblent partager des caractéristiques communes ?
- 5. En observant la disposition générale :
 - o Comment se distribuent les athlètes le long du premier axe (Dim 1)?
 - Et le long du second axe (Dim 2)?

Dimensionality Reduction using Factoshiny

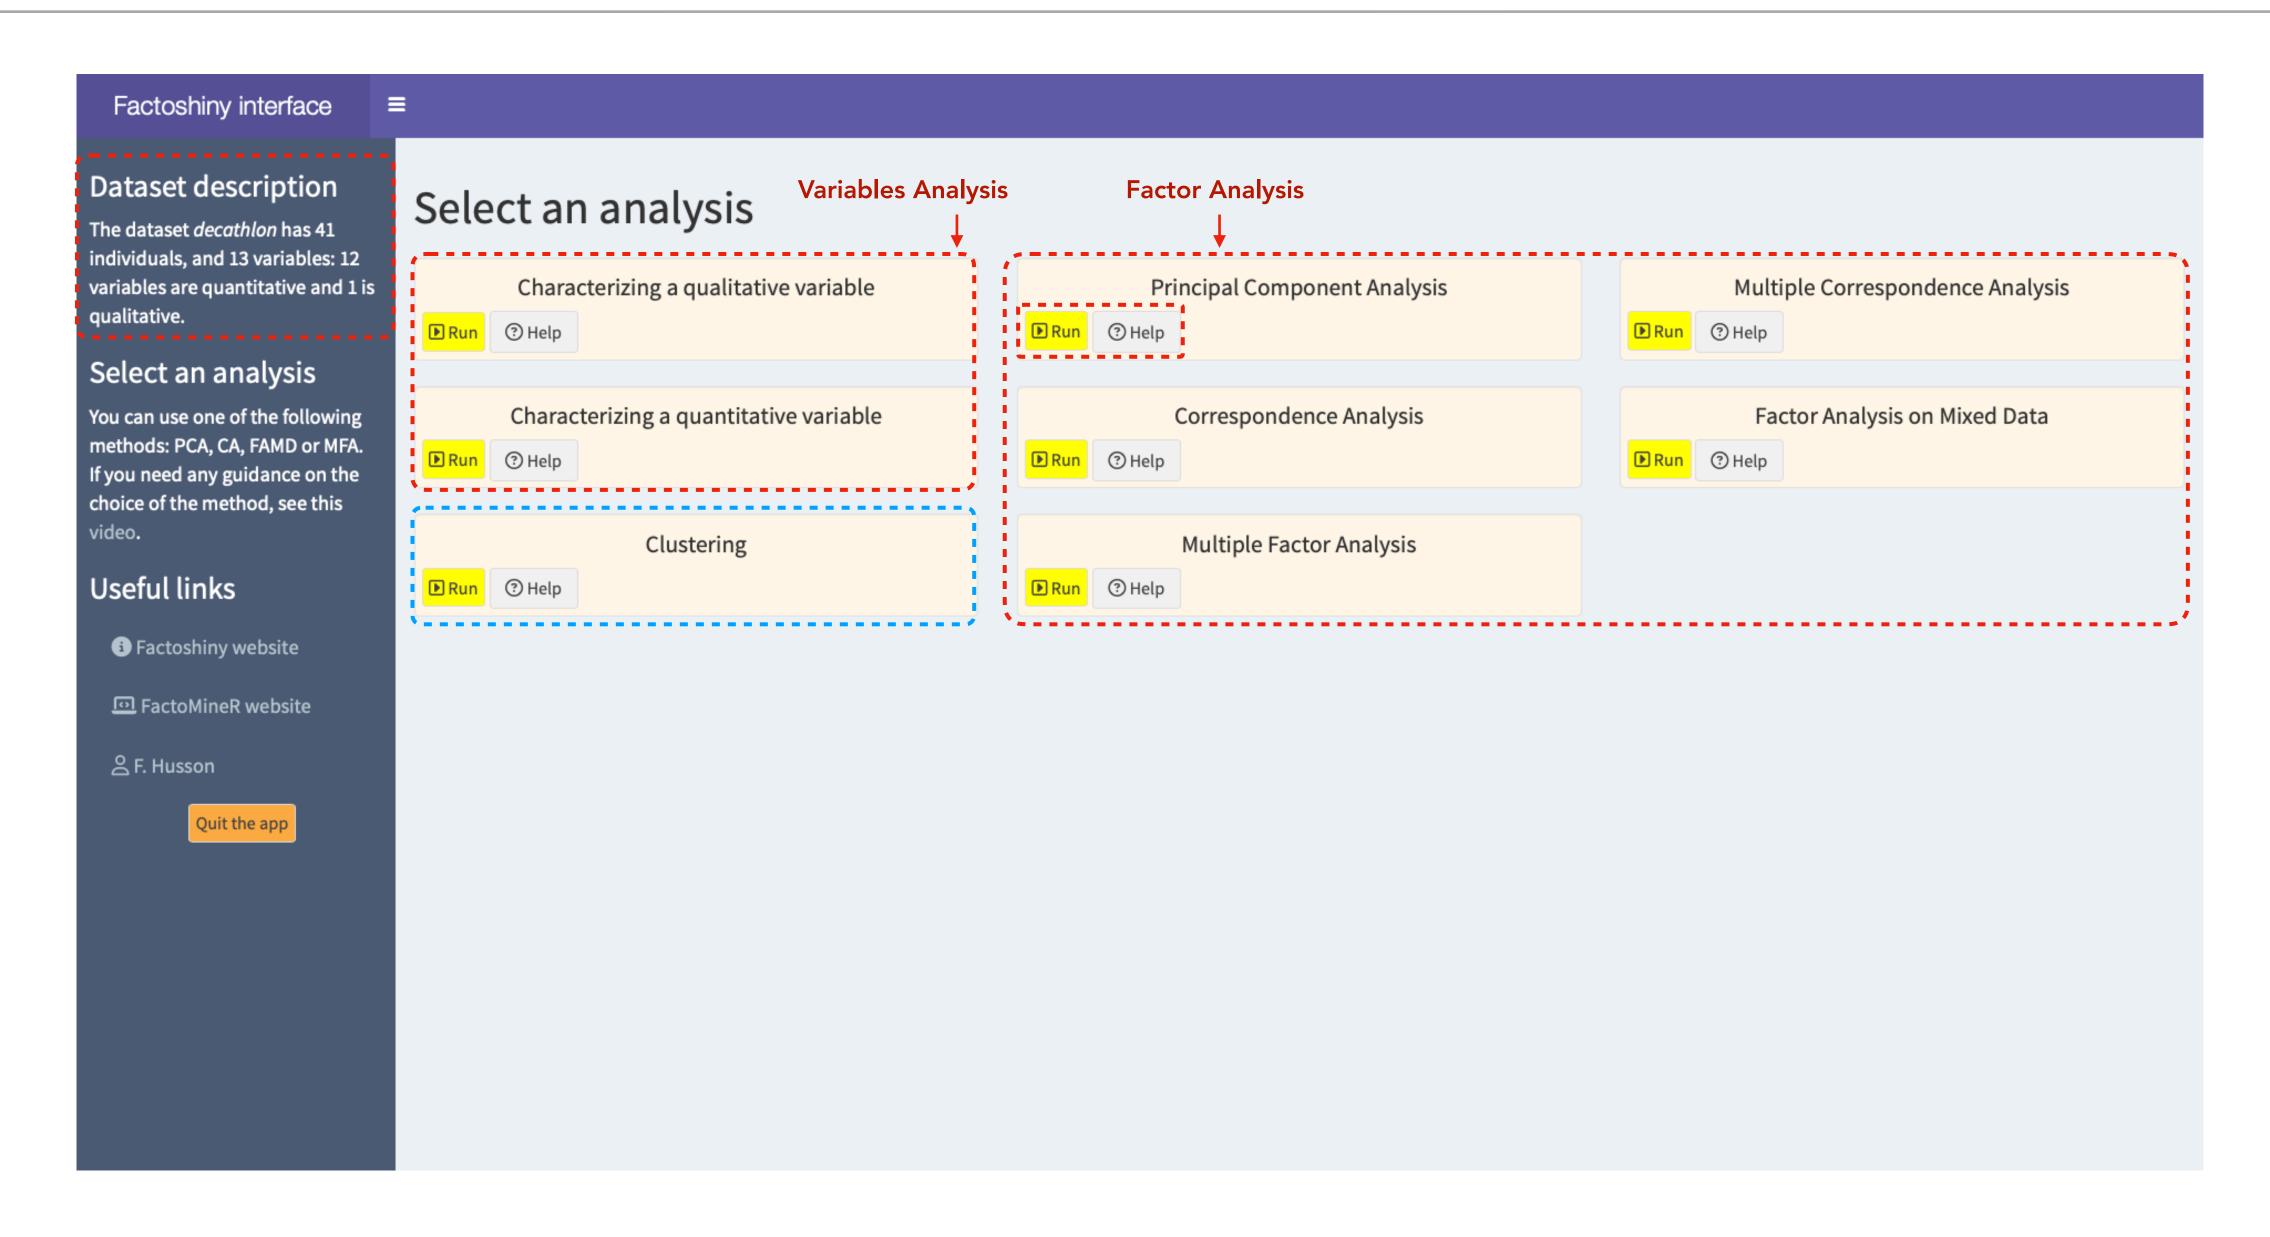
Factoshiny

- Factoshiny is a graphical and interactive interface built on top of the FactoMineR package.
- It allows users to perform multivariate analyses (PCA, CA, MCA, HCPC, MFA, etc.) without writing R code.
- o Designed for teaching, quick exploration, and reporting.
- Ideal for presenting analyses to non-technical audiences.
- How It Works. Launch Factoshiny with one line of R code:

> res = Factoshiny(dataset)


• The app opens a web interface (via Shiny) in your browser.

PCA using R



PCA using R

Results



PCA using R

